Università di Pisa – Dipartimento di Ingegneria dell'Informazione
Corso di Laurea Magistrale in Ingegneria Robotica e dell'Automazione

Reinforcement Learning On-Policy Multi-Agente per la Guida e il Coordinamento di Formazioni Satellitari in Orbita Cislunare

Progettazione, addestramento e valutazione comparativa di un GNC-PPO Formation Manager per costellazioni satellitari nell'intorno dell'orbita Halo L_2 Terra-Luna

Riassunto esteso della tesi di Laurea Magistrale

Relatore: Prof.ssa Giordana Bucchioni
Candidato: Andrea Sodini

Anno Accademico 2025/2026

1 Contesto e motivazioni

Il progressivo spostamento dell'interesse delle agenzie spaziali verso l'ambiente lunare, come per il caso dei programmi Artemis, o di infrastrutture come il Lunar Gateway, ha reso rilevante lo studio di missioni con più veicoli spaziali cooperanti in formazione su orbite non kepleriane, tipicamente Halo o Near-Rectilinear Halo, attorno ai punti lagrangiani del sistema Terra-Luna. In questo scenario, nel quadro del progetto *MUSAPOEM*, operazioni di prossimità come rendez-vous, mantenimento della visibilità reciproca e mantenimento della connettività di rete della formazione sono rese complesse dalla natura non lineare della dinamica di riferimento, il Problema Circolare Ristretto dei Tre Corpi (CR3BP).

I quattro ruoli della formazione hanno funzioni complementari e non intercambiabili: il target definisce passivamente il riferimento orbitale Halo; il chaser esegue il rendez-vous vero e proprio, riducendo la propria distanza dal target fino alla soglia operativa di 1 km; l'observer si posiziona in modo da mantenere simultaneamente nel proprio campo visivo target e chaser, a supporto della supervisione della manovra; il comm massimizza la connettività di rete della costellazione, fungendo da relay di comunicazione verso Terra. Le tecniche di guida, navigazione e controllo classiche si basano su modelli dinamici espliciti e metodi di ottimizzazione mediante algoritmi genetici risolti punto per punto a ogni ciclo di pianificazione, secondo un approccio impiegato anche per il mantenimento di traiettorie periodiche nell'intorno di punti lagrangiani [16]: il lavoro di riferimento di Pilone [1] ha affrontato con questo approccio, centralizzato e decentralizzato, lo stesso scenario di missione qui ripreso. Questi metodi, per quanto accurati, richiedono un costo computazionale online significativo e risultano poco robusti quando le condizioni operative si discostano da quelle di progetto. Questa tesi esplora un paradigma alternativo, il *Reinforcement Learning* (RL) *on-policy*, in cui un agente apprende una politica di controllo $\pi(a|s)$ interagendo ripetutamente con un ambiente simulato, spostando l'onere computazionale dalla fase operativa a quella di addestramento offline; tra gli algoritmi on-policy, il *Proximal Policy Optimization* (PPO) [3] è scelto per la sua stabilità di addestramento e la naturale applicabilità a spazi di azione discreti.

Il caso di studio è una formazione di quattro satelliti, costituita daun *target* passivo, un *chaser* attivo, un *observer* e un satellite di *comunicazione* (comm), orbitante attorno a un'orbita Halo Sud-polare L_2 Terra-Luna. L'obiettivo è definire un *Formation Manager* autonomo, il cui contributo metodologico centrale consiste nel confronto tra tre approcci operativi: due varianti dell'ambiente di simulazione che differiscono unicamente per la strategia di avanzamento temporale, passo di integrazione fisso e passo adattivo, e un terzo scenario in cui gli obiettivi geometrici di observer e comm sono sostituiti dall'ancoraggio a un toro quasi-halo invariante della dinamica CR3BP.

L'applicazione del RL alla guida e al controllo di veicoli spaziali è un'area di ricerca attiva: la rassegna di Tipaldi *et al.* [7] sistematizza i principali contributi su controllo di assetto, controllo orbitale e operazioni di prossimità, evidenziando negli algoritmi actor-critic on-policy, PPO su tutti, un buon compromesso fra stabilità di addestramento e qualità della politica appresa. Con specifico riferimento alla dinamica a tre corpi, Bosanac *et al.* [9] hanno applicato PPO multi-obiettivo a trasferimenti a

basso spinta fra orbite Halo, mentre Federici *et al.* [10] e Qu *et al.* [11] hanno impiegato deep learning e RL per la guida autonoma in prossimità e per il rendez-vous con *collision avoidance*; questi lavori condividono con la tesi l'idea di sostituire la pianificazione esplicita con una politica appresa, ma si concentrano su un singolo veicolo, senza la gestione distribuita di una formazione multi-satellite qui proposta.

2 Modello dinamico: CR3BP e manovre di Lambert

Il riferimento dinamico adottato è il CR3BP [2]: Terra e Luna, di parametro di massa $\mu = 0.0121506$, orbitano circolarmente attorno al baricentro comune, mentre il satellite, di massa trascurabile, ne risente la sola attrazione gravitazionale. Nel frame sinodico adimensionale, con r_1, r_2 distanze del satellite dai due primari, le equazioni del moto sono

$$\ddot{x} - 2\dot{y} = x - (1-\mu)\frac{x+\mu}{r_1^3} - \mu\frac{x-1+\mu}{r_2^3}, \quad \ddot{y} + 2\dot{x} = y - (1-\mu)\frac{y}{r_1^3} - \mu\frac{y}{r_2^3}, \quad \ddot{z} = -(1-\mu)\frac{z}{r_1^3} - \mu\frac{z}{r_2^3}. \tag{1}$$

Queste equazioni discendono dal potenziale efficace $U^*(x,y,z) = \frac{1}{2}(x^2+y^2) + \frac{1-\mu}{r_1} + \frac{\mu}{r_2}$, i cui punti stazionari sono i cinque punti di equilibrio del sistema, i punti di Lagrange (Fig. 1),

$$\nabla U^* = 0 \implies L_1,\, L_2,\, L_3,\, L_4,\, L_5, \tag{2}$$

tre collineari (L_1, L_2, L_3) e due equilateri (L_4, L_5). Il punto L_2 Terra-Luna, instabile come tutti i punti collineari, si colloca a circa 64 500 km oltre il centro della Luna e ospita famiglie di orbite periodiche tridimensionali dette Halo, di ampiezza fuori-piano A_z; l'orbita di riferimento condivisa dai tre scenari è una Halo Sud-polare a risonanza sinodica 9:2 (periodo $T \approx 157.5$ h), coerente con l'architettura del Lunar Gateway e con il caso di studio di Pilone [1], determinata per correzione differenziale Newton-Raphson non esistendo una soluzione analitica in forma chiusa.

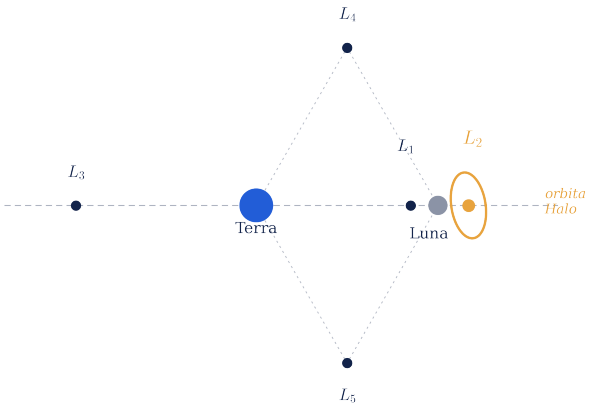


Figura 1: Punti di Lagrange del sistema Terra-Luna e orbita Halo di riferimento attorno a L_2.

Attorno a un'orbita Halo periodica $\mathbf{s}_{\text{halo}}(t)$, soluzione delle equazioni del moto $\dot{\mathbf{s}} = f(\mathbf{s})$, la dinamica linearizzata di una perturbazione $\delta\mathbf{s}$ è governata dalla Jacobiana $A(t) = \partial f/\partial \mathbf{s}$ valutata sull'orbita,

$$\dot{\mathbf{s}}_{\text{halo}} = f(\mathbf{s}_{\text{halo}}), \qquad \delta\dot{\mathbf{s}} = A(t)\,\delta\mathbf{s}, \qquad \dot{\Phi}(t,t_0) = A(t)\,\Phi(t,t_0), \quad \Phi(t_0,t_0) = I, \tag{3}$$

dove $\Phi(t,t_0)$ è la matrice di transizione di stato. Quando gli autovalori di Φ sul periodo includono una coppia complessa coniugata di modulo unitario: in questo caso, le orbite quasi-periodiche nell'intorno della Halo sono approssimate al primo ordine da

$$\mathbf{s}(t,\theta_2) \approx \mathbf{s}_{\text{halo}}(t) + A\,\mathrm{Re}\big[\Phi(t)\,\hat{\mathbf{v}}\,e^{-i\theta_2}\big], \tag{4}$$

con A ampiezza dell'oscillazione attorno alla Halo [12, 13]: al variare di A si ottiene l'intera famiglia di tori quasi-halo invarianti, che biforca dalla famiglia Halo periodica ed è alla base della terza variante metodologica (Sez. 6.3), e viene usata come riferimento di traiettoria per observer e comm.

Ogni manovra simulata è un trasferimento bi-impulsivo generato risolvendo il problema di Lambert per *shooting* numerico *all'interno della dinamica completa del CR3BP*: non esistendo, a differenza del caso kepleriano, una soluzione analitica in forma chiusa, si parte da una stima $\mathbf{v}_0^{(k)}$ della velocità iniziale, si propaga lo stato per il tempo di volo assegnato ottenendo la posizione finale $\mathbf{r}_f^{(k)}$, e si corregge $\mathbf{v}_0$ per iterazioni di Newton-Raphson fino a convergenza entro una tolleranza prefissata sulla posizione di arrivo desiderata $\mathbf{r}_{\text{arr}}$,

$$\mathbf{e}^{(k)} = \mathbf{r}_f^{(k)} - \mathbf{r}_{\text{arr}}, \qquad J\,\delta\mathbf{v} = -\mathbf{e}^{(k)}, \qquad \mathbf{v}_0^{(k+1)} = \mathbf{v}_0^{(k)} + \delta\mathbf{v}, \tag{5}$$

dove $J = \partial\mathbf{r}_f/\partial\mathbf{v}_0$ è lo Jacobiano 3×3 della posizione finale rispetto alla velocità di partenza, valutato per differenze finite.

Le grandezze relative fra i satelliti della formazione sono infine espresse nel frame locale *Local Vertical Local Horizon* (LVLH), solidale con il target: asse radiale $\hat{R}$ lungo la posizione del target, asse normale orbitale $\hat{W}$ lungo il momento angolare specifico, asse trasversale $\hat{S} = \hat{W} \times \hat{R}$. La posizione e velocità relativa di ciascun satellite attivo rispetto al target sono ottenute *a posteriori*, come trasformazione di coordinate applicata agli stati assoluti, propagati indipendentemente nel frame sinodico.

3 Reinforcement Learning on-policy e PPO

Il problema è formulato come Processo Decisionale di Markov $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$: $\mathcal{S}$ è lo spazio degli stati, $\mathcal{A}$ lo spazio delle azioni, $P(s'|s,a)$ la probabilità di transizione, $R(s,a)$ la ricompensa immediata e $\gamma \in [0,1)$ lo sconto sulle ricompense future. Ogni agente è dotato di una rete *actor-critic* (Fig. 2), il cui tronco condiviso $[128, 128, 64]$ riceve in ingresso lo stato osservato s_t e si dirama in due teste: l'*actor head*, che produce una distribuzione categoriale sulle azioni discrete disponibili, e la *critic head*, che produce una stima scalare del valore dello stato $V_\phi(s_t)$. Dalla distribuzione dell'actor si campiona l'azione effettivamente eseguita,

$$a_t \sim \pi_\theta(\cdot \,|\, s_t), \tag{6}$$

dove π_θ è la politica, parametrizzata dai pesi θ condivisi da tronco e actor head. L'azione campionata diventa il trasferimento di Lambert eseguito nell'ambiente, che restituisce il reward immediato r_t (Sez. 4.3) e lo stato successivo s_{t+1}: il ciclo stato-rete-azione-ambiente si ripete finché non si raccolgono 1024 passi (Tabella 2), senza aggiornare mai la rete nel frattempo.

Terminata la raccolta, per ciascun passo si valuta quanto l'azione presa si sia discostata dall'aspettativa del critic. Il ritorno atteso $Q(s_t, a_t)$ viene approssimato dal residuo temporale fra reward osservato e stima del critic sullo stato successivo,

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t), \tag{7}$$

combinando il quale su più passi, con peso decrescente secondo λ_{GAE} (*Generalized Advantage Estimation*, $\lambda = 0.95$), si ottiene il vantaggio A_t. In parallelo il critic viene corretto per avvicinare la propria stima al ritorno realmente osservato,

$$L^V(\phi) = \tfrac{1}{2}\big(V_\phi(s_t) - R_t\big)^2, \qquad R_t = \sum_{\tau \geq t} \gamma^{\tau - t} R(s_\tau, a_\tau). \tag{8}$$

Con vantaggi e ritorni calcolati, si passa all'aggiornamento: il rollout viene diviso in minibatch da 256 e riattraversato per 10 epoche (Tabella 2), 40 correzioni in tutto. Per ciascun minibatch si ricalcola quindi il rapporto fra probabilità nuova e congelata,

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}, \tag{9}$$

pari a 1 solo se $\theta = \theta_{\text{old}}$, maggiore di 1 se l'azione è diventata più probabile nel frattempo, minore altrimenti. PPO massimizza un obiettivo *clippato*,

$$L^{\text{CLIP}}(\theta) = \min\big(r_t(\theta)\,A_t,\ \text{clip}(r_t(\theta),\,1-\epsilon,\,1+\epsilon)\,A_t\big), \tag{10}$$

dove clip$(\cdot)$ satura $r_t(\theta)$ in $[1-\epsilon, 1+\epsilon]$ ($\epsilon = 0.2$): con $A_t > 0$ il clipping impedisce che l'azione diventi troppo più probabile in un colpo solo, con $A_t < 0$ ne limita analogamente la riduzione. La loss combinata viene poi derivata rispetto a ogni peso tramite backpropagation e ciascun peso corretto in proporzione al proprio gradiente (learning rate, Tabella 2): poiché actor e critic condividono il tronco, ogni correzione aggiorna l'intera rete. Esaurite le 10 epoche, θ_{old} viene sostituito dal θ raggiunto e si torna a raccogliere un rollout nuovo. Rispetto al GNC classico, la politica così appresa offre valutazione online quasi istantanea, robustezza a variazioni parametriche acquisita offline, e scalabilità a obiettivi geometrici distinti per ruolo.

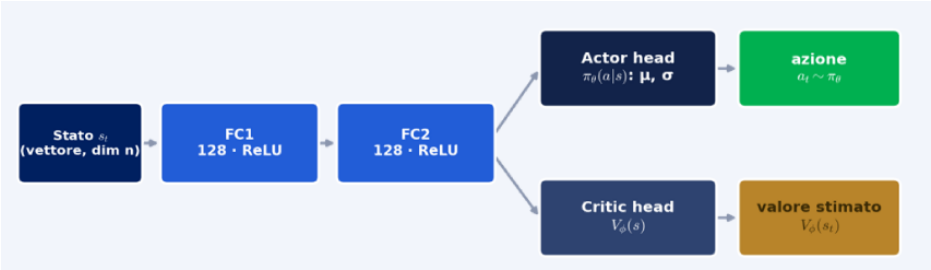


Figura 2: Architettura actor-critic impiegata da ciascun agente PPO: rete condivisa $[128, 128, 64]$, testa attore (politica categoriale) e testa critico (valore stimato).

Quando più agenti sono addestrati simultaneamente, l'ambiente percepito da ciascuno diviene non stazionario. La letteratura propone principalmente il paradigma *Centralized Training Decentralized Execution* (CTDE, critico centralizzato, es. MADDPG [5], MAPPO [4]) e il paradigma completamente decentralizzato; questa tesi adotta un terzo compromesso, il *curriculum learning sequenziale* (Sez. 4), motivato e confrontato con i primi due nella Fig. 3.

4 Metodologia

4.1 Architettura software e i tre scenari a confronto

I tre scenari (`RLFM_FreeSpace_Fixed`, `RLFM_FreeSpace_Var`, `RLFM_qHalo`) condividono la stessa orbita Halo L_2 Sud-polare di riferimento, lo stesso motore di manovra Lambert, gli stessi iperparametri PPO e lo stesso curriculum a cinque fasi, differendo per gli aspetti riassunti in Tabella 1.

	Fixed	**Var (adattivo)**	**Quasi-Halo (qHalo)**
Passo dt	costante, 30 min	FSM a 4 fasi: FAR 90 min → MID 60 min → NEAR 45 min → FINAL 30 min	costante, 30 min
Obiettivo obs/comm	standoff geometrico in spazio libero	standoff geometrico in spazio libero (identico a Fixed)	ancoraggio a un toro quasi-halo invariante (5 shell, 2.4–9.5 km)
FOV obs. / antenna comm	cono 30° / 100 km	come Fixed	cono 30° / 30 km
Tempi di volo (ToF)	2–42.5 h	come Fixed	come Fixed (chaser); sottoinsieme corto per hop/shell

Tabella 1: Confronto sintetico dei tre scenari sperimentali.

4.2 Spazio di osservazione e spazio delle azioni

Lo spazio di osservazione concatena lo stato relativo LVLH proprio e quello degli altri due agenti attivi, un blocco di scalari geometrici globali e i cooldown di manovra residui,

$$o = \left[\boldsymbol{\rho}^L_{\text{self}},\ \boldsymbol{\rho}^L_{\text{other},1},\ \boldsymbol{\rho}^L_{\text{other},2},\ s,\ c\right], \qquad \boldsymbol{\rho}^L_{(\cdot)} \in \mathbb{R}^6\ (\times 3), \quad s \in \mathbb{R}^8, \quad c \in \mathbb{R}^3, \tag{11}$$

per una dimensione totale $N_{\text{obs}} = 29$ (Fixed/Var) o 31 (qHalo, due scalari aggiuntivi per lo stato del toro); $\boldsymbol{\rho}^L_{\text{self}}$ e $\boldsymbol{\rho}^L_{\text{other},i}$ sono le posizioni/velocità relative in LVLH proprie e degli altri due agenti, s raccoglie grandezze scalari condivise (distanza chaser-target, connettività λ_2, frazione di episodio trascorsa, Δv cumulati dei tre agenti, distanze residue di observer e comm dal proprio obiettivo), c i tempi di cooldown residui delle manovre in corso. Lo spazio delle azioni è discreto,

$$a \in \{0, 1, \ldots, N_{\text{act}}-1\}, \qquad N_{\text{act}} = 1 + N_{\text{ToF}} \times N_{\Delta v} = 1 + 8 \times 5 = 41, \tag{12}$$

con l'azione 0 corrispondente a *coast* (nessuna manovra) e le restanti 40 a un trasferimento di Lambert dato dalla combinazione di uno fra $N_{\mathrm{ToF}} = 8$ tempi di volo disponibili e una fra $N_{\Delta v} = 5$ frazioni del budget di Δv residuo; nella variante qHalo, observer e comm dispongono inoltre di azioni di *hop di fase* sul toro (variazione dell'angolo θ_2 a shell invariata) e di *cambio di shell* (fra le 5 shell disponibili, con un moltiplicatore di Δv crescente con l'ampiezza del salto), per un totale rispettivamente di $N_{\mathrm{act}}^{\mathrm{comm}} = 197$ e $N_{\mathrm{act}}^{\mathrm{obs}} = 981$ azioni.

4.3 Funzione di reward multi-agente

Il reward, condiviso – byte-identico – da Fixed e Var, è costruito secondo il principio del *potential-based shaping*: per il chaser, il potenziale φ_c è definito in scala logaritmica sulla distanza dal target d_c, con soglia di successo $d_{\mathrm{goal}} = 1\,\mathrm{km}$ usata come limite inferiore per evitare divergenze quando $d_c \to 0$,

$$\varphi_c = 100\Big[\ln\big(\max(d_c^{\mathrm{prev}}, d_{\mathrm{goal}})\big) - \ln\big(\max(d_c^{\mathrm{now}}, d_{\mathrm{goal}})\big)\Big], \qquad r_c = \varphi_c - 8.0\,\Delta v_c^{\mathrm{step}} + 50 \cdot \mathbb{1}[\text{successo}], \tag{13}$$

dove $\Delta v_c^{\mathrm{step}}$ è il Δv impiegato al passo corrente e $\mathbb{1}[\cdot]$ l'indicatore del raggiungimento della soglia. L'observer combina un potenziale φ_o analogo, rispetto a un punto di standoff sfalsato dal midpoint target-chaser, con due penalità geometriche,

$$r_o = \varphi_o - 8.0\,\Delta v_o^{\mathrm{step}} - p_{\mathrm{fov}} - p_{\mathrm{asym}}, \qquad p_{\mathrm{fov}} = 5\,\frac{\theta_{\mathrm{fov}} - 30^\circ}{150^\circ} \;\; (\theta_{\mathrm{fov}} > 30^\circ), \tag{14}$$

dove θ_{fov} è l'angolo sotteso da target e chaser visto dall'observer (penalizzato solo oltre il limite operativo di 30°) e $p_{\mathrm{asym}} = 4\tanh(|d_t - d_c|/500\,\mathrm{km})$ penalizza l'asimmetria fra le distanze observer-target d_t e observer-chaser d_c. Il comm combina un potenziale φ_k sullo scostamento dalla fascia di standoff $[10, 30]\,\mathrm{km}$ con un termine incrementale e uno assoluto sull'autovalore di Fiedler λ_2 della matrice Laplaciana pesata della formazione,

$$r_k = \varphi_k + 20\big(\lambda_2^{\mathrm{now}} - \lambda_2^{\mathrm{prev}}\big) + 3\,\lambda_2^{\mathrm{now}} - 10.0\,\Delta v_k^{\mathrm{step}}, \tag{15}$$

dove λ_2 è il secondo autovalore, in ordine crescente, della Laplaciana $L = D - W$ del grafo pesato a quattro nodi della formazione, con pesi $w_{ij} = \exp(-\|\mathbf{r}_i - \mathbf{r}_j\|/d_{\mathrm{ref}})$ troncati a zero oltre la portata fisica R_{comm} dell'antenna (50 e 100 km rispettivamente per Fixed/Var). La variante qHalo sostituisce, per observer e comm, il potenziale geometrico con una penalità di corridoio rispetto alla shell assegnata sul toro quasi-halo,

$$p_{\mathrm{corridor}} = K_{\mathrm{corridor}}\Big[\min\Big(\max\big(0, \tfrac{\mathrm{dev}}{\mathrm{dev}_{\mathrm{tol}}} - 1\big), 5\Big)\Big]^2 + K_{\mathrm{track}}\,\frac{\mathrm{dev}}{\mathrm{dev}_{\mathrm{tol}}}, \tag{16}$$

dove dev è la deviazione dalla shell assegnata, $\mathrm{dev}_{\mathrm{tol}}$ la tolleranza di corridoio (2.6 km per l'observer, 4.3 km per il comm, antenna 30 km) e $K_{\mathrm{corridor}} = 17$, $K_{\mathrm{track}} = 1.5$ i pesi, rispettivamente, del termine quadratico di contenimento e di quello lineare di inseguimento fine.

4.4 Curriculum learning e coordinamento multi-agente

L'addestramento simultaneo da zero di tre agenti fortemente accoppiati rende difficile definire un training efficace: il reward dell'observer dipende dalla posizione del chaser, quello del comm da entrambi, e ciò rischierebbe di non produrre, per nessuno dei tre, un segnale di apprendimento stabile. Si adotta perciò un *curriculum learning sequenziale* a cinque fasi, implementato nella classe `MultiAgentPPOTrainer`: (1) *bootstrap del chaser* in isolamento; (2) *bootstrap di observer e comm*, singolarmente, contro il chaser già parzialmente addestrato e mantenuto fisso; (3–5) *raffinamento congiunto*, in più round successivi in cui ciascun agente osserva le politiche correnti degli altri due come parte, via via più stabile, della dinamica dell'ambiente. Ogni sottofase riceve un budget minimo garantito proporzionale a un moltiplicatore e avanza oltre tale minimo solo se il tasso di successo, calcolato come media mobile, supera stabilmente una soglia di convergenza specifica per fase, tipicamente 85–90%; questo evita di consegnare alla fase successiva una politica non ancora stabilizzata, cosa che un budget rigido a lunghezza fissa non garantirebbe.



Figura 3: I tre paradigmi di coordinamento multi-agente considerati: CTDE (critico centralizzato), training completamente decentralizzato, e il curriculum sequenziale adottato in questa tesi.

5 Setup sperimentale

Ciascun agente impiega una rete actor-critic $[128, 128, 64]$; gli iperparametri PPO, identici nei tre scenari, sono riportati in Tabella 2. Il valore di discount $\gamma = 0.999$, superiore allo standard 0.99 tipico dei benchmark di controllo continuo, è stato scelto per adattarsi alla scala temporale estesa del problema: un episodio può estendersi per centinaia di passi, ciascuno corrispondente a minuti od ore di tempo di missione, e un orizzonte di credit assignment più corto lasciava sostanzialmente "invisibili" al segnale di training le conseguenze di una manovra prematura. La valutazione finale di tutte e tre le configurazioni è condotta su $N = 10\,000$ episodi indipendenti, con politica *deterministica*, ossia azione a probabilità massima, e condizioni iniziali generate con seed distinti da quelli di addestramento: in particolare posizione iniziale del chaser a 50–300 km dal target, dell'observer a 20–40 km, del comm a 40–80 km, con velocità relativa iniziale di 5 m/s in direzione casuale. L'implementazione è sviluppata in Python, con NumPy e SciPy per l'integrazione numerica e la determinazione delle condizioni iniziali dell'orbita Halo, Gymnasium [14] per l'interfaccia standard dell'ambiente e Stable-Baselines3 [15] per l'algoritmo PPO.

Passi per rollout	1024	Clipping ϵ	0.2
Minibatch	256	Learning rate	3×10^{-4}
Epoche per rollout	10	Discount γ	0.999
GAE λ	0.95	Rete actor/critic	$[128, 128, 64]$

Tabella 2: Iperparametri PPO, identici per i tre scenari e per tutti gli agenti.

6 Risultati

6.1 Scenario a passo fisso - Fixed

Sul campione a $N = 10\,000$ episodi, il tasso di successo del rendez-vous del chaser è 96.8%, con distanza minima media di 3.52 km e Δv medio di 25.8 m/s; sul campione di validazione preliminare, un solo episodio su 100 mostrava una distanza chaser-target divergente oltre i 700 km, coerente in ordine di grandezza con il 3.2% di fallimento osservato sul campione esteso. La Fig. 4 mostra, in alto, il profilo di velocità relativa al target dei tre agenti attivi in un episodio rappresentativo – con le brusche variazioni corrispondenti alle manovre impulsive di Lambert – e, in basso, la geometria di connettività del comm rispetto alla portata dell'antenna (100 km) e l'evoluzione dell'autovalore di Fiedler λ_2, che si mantiene ben al di sopra della soglia di rete disconnessa ($\lambda_2 = 0$) non appena la formazione si stabilizza, in linea con il valore medio $\lambda_2 = 2.06$ misurato sul campione esteso. Il consumo medio di observer e comm è rispettivamente 10.4 e 11.7 m/s: valori tutt'altro che trascurabili, coerenti con la maggiore difficoltà del loro compito – inseguire un punto-goal geometrico mobile, definito rispetto alla posizione ancora in evoluzione degli altri agenti, piuttosto che un bersaglio fisso.

6.2 Scenario a passo adattivo - Var

Nella variante a passo adattivo, il dt si riduce da 90 min (fase FAR) a 30 min (fase FINAL, identico al passo fisso) in funzione della distanza chaser-target: il passo di propagazione è limitato superiormente dal tempo di coast residuo più breve fra tutte le manovre attive. A parità di curriculum, il Δv medio si riduce per tutti gli agenti attivi rispetto al passo fisso: circa il 34% in meno per il chaser (da 25.8

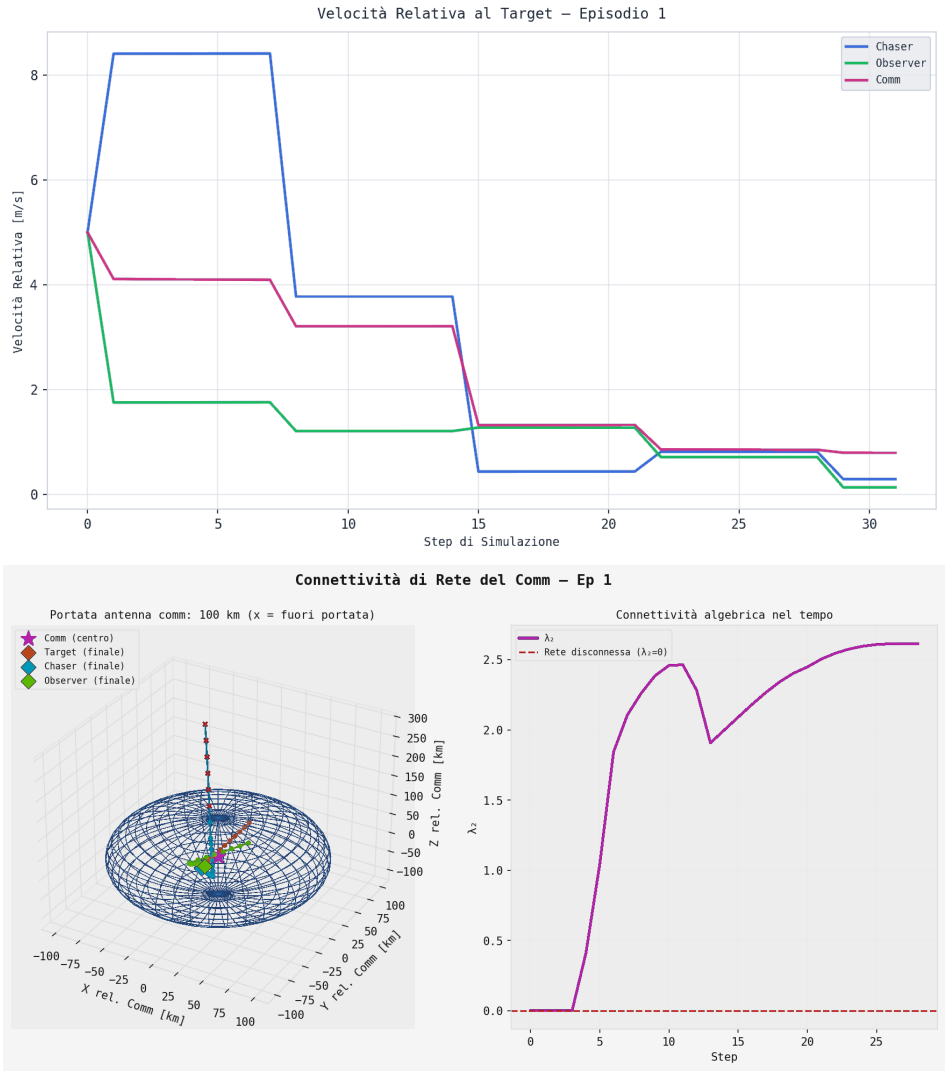


Figura 4: Scenario Fixed: velocità relativa al target di chaser, observer e comm (sopra); geometria di portata dell'antenna comm e connettività algebrica λ_2 nel tempo (sotto).

a 17.2 m/s), il 14% per l'observer (8.9 m/s) e il 21% per il comm (9.3 m/s), a fronte di un tasso di successo lievemente inferiore (93.6%); questo comportamento è dovuto al fatto che in una percentuale degli episodi il consumo di carburante del chaser risulta superiore rispetto ai valori limite imposti: infatti, nella prima fase delle manovre, il chaser risulta essere più aggressivo rispetto al caso Fixed e ne conseguono manovre più costose. La connettività algebrica media, $\lambda_2 = 2.28$, risulta la più alta fra le due varianti free-space, coerente con la migliore aderenza allo standoff del comm (92.5% di permanenza in portata rispetto al chaser, 99.5% rispetto all'observer, 97.8% rispetto al target). Il forte scarto fra distanza minima media e mediana del chaser (7.72 contro 0.93 km) segnala una distribuzione fortemente asimmetrica: la maggioranza degli episodi converge molto vicino al target, mentre una minoranza ben identificabile, una coda di fallimento associata a specifiche manovre di tempo di volo, si allontana in modo sostanziale, spostando la media senza spostare la mediana. La Fig. 5 riporta il riepilogo statistico su un campione di 100 episodi del batch di valutazione e la geometria/connettività del comm, qualitativamente analoga a quella del passo fisso ma raggiunta con un consumo inferiore.

6.3 Scenario di ancoraggio al toro quasi-halo (qHalo)

Nella terza variante, observer e comm non inseguono più un bersaglio geometrico in spazio libero ma restano ancorati a una shell del toro quasi-halo invariante, costruito numericamente attorno all'orbita Halo di riferimento. Il tasso di successo del rendez-vous del chaser risulta il più alto delle tre configurazioni, 99.2% (Fig. 6, in alto), con distanza minima media pari a 2.03 km, valore lievemente innalzato, rispetto alla soglia di successo di 1 km, dal ridotto numero di episodi falliti (0.8% del campione), a fronte di un Δv del chaser leggermente superiore (29.0 m/s). Il vantaggio energetico

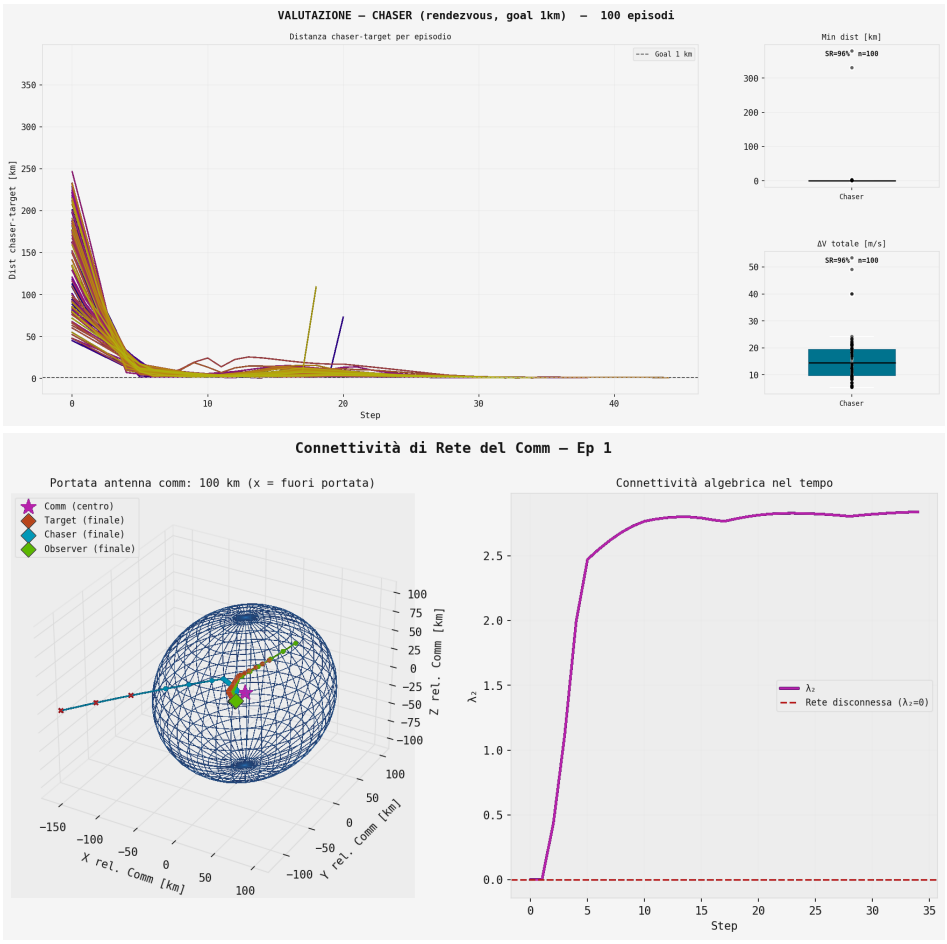


Figura 5: Scenario Var: valutazione riepilogativa del chaser – distanza dal target e box-plot di Δv (sopra); geometria di portata dell'antenna comm e connettività algebrica (sotto).

atteso si osserva invece nettamente per observer e comm, il cui consumo medio (2.8 e 1.1 m/s) è drasticamente inferiore a quello delle varianti free-space: restare in prossimità di un'ancora che è essa stessa soluzione del flusso del CR3BP richiede, in linea di principio, uno sforzo di controllo minore di quello necessario per inseguire un bersaglio funzionale scorrelato dalla dinamica locale. La deviazione dal toro ideale (Fig. 6, in basso) resta contenuta, con mediana di 0.016 km per l'observer e 0.072 km per il comm (21.5% e 7.7% degli episodi oltre la rispettiva tolleranza di corridoio). Il vincolo di FOV dell'observer, per costruzione ancorato a poche centinaia di metri dal target, risulta soddisfatto fino al 58% del tempo di missione: in *far range* lo scarto minimo fisso dell'observer rende l'angolo target-chaser ampio, mentre l'angolo converge naturalmente sotto i 30° non appena il chaser rientra in *mid/near range*.

6.4 Confronto sintetico fra le tre varianti

La Fig. 7 e la Tabella 3 riassumono il confronto sulle metriche principali. Il confronto diretto Fixed/Var mostra come il timestep adattivo riduca sistematicamente il consumo energetico di tutti gli agenti attivi, al costo di un tasso di successo lievemente inferiore, spiegato da una minoranza ben identificabile di episodi problematici (mediana della distanza minima del chaser pari a soli 0.93 km, contro una media di 7.72 km, a riprova di una distribuzione fortemente asimmetrica) più che da un degrado diffuso delle prestazioni. La variante qHalo, pur con un Δv del chaser leggermente più elevato, ottiene il miglior tasso di successo assoluto e un costo di mantenimento di formazione per observer e comm nettamente inferiore. Il confronto con l'approccio di ottimizzazione esplicita di Pilone [1], che ha affrontato lo stesso scenario di missione con schemi centralizzati (ottimizzazione a forza bruta, discreta e continua) e decentralizzati sequenziali/paralleli, conferma il vantaggio computazionale online atteso della politica appresa (un singolo forward pass, ordine del millisecondo, contro decine-centinaia di secondi per ciclo di pianificazione), a fronte dell'assenza delle garanzie formali di ottimalità proprie dell'ottimizzazione esplicita: la politica RL sposta l'intero costo computazionale alla fase di addestramento offline, mentre l'approccio classico, più accurato punto per

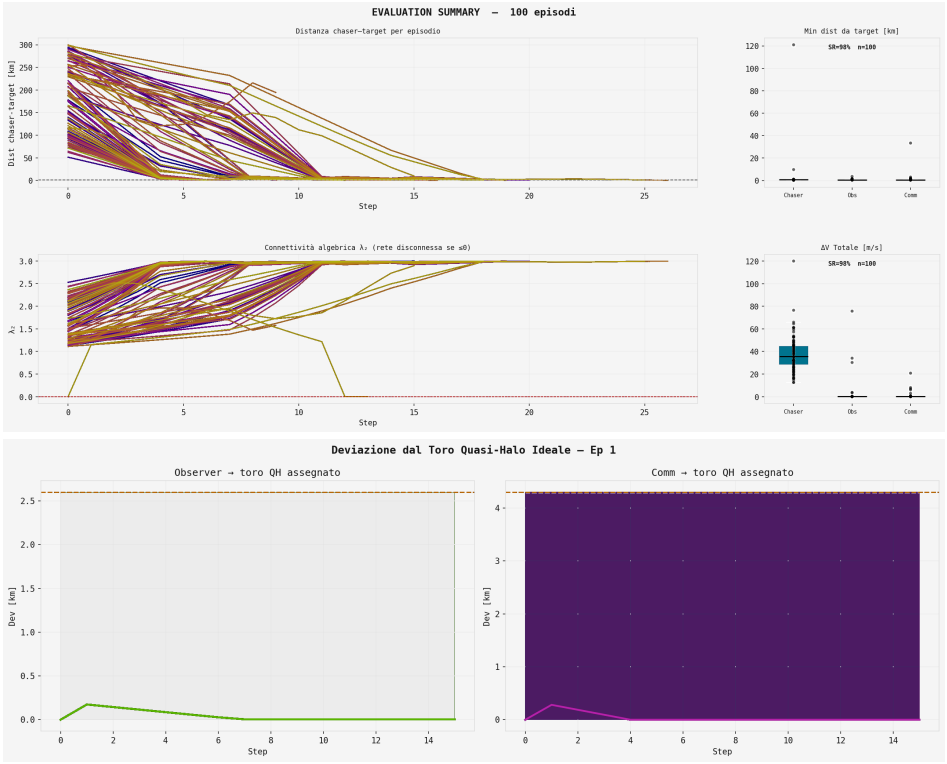


Figura 6: Scenario qHalo: valutazione riepilogativa del chaser su 100 episodi (sopra); deviazione di observer e comm dal toro quasi-halo ideale nel tempo (sotto).

punto, ma privo di una fase di apprendimento, richiede la soluzione di un problema vincolato non lineare a ogni ciclo di ripianificazione operativa.

	Fixed	**Var (hardened)**	**Quasi-Halo**
Tasso di successo (chaser)	96.8%	93.6%	**99.2**%
Δv medio chaser [m/s]	25.8	17.2	29.0
Δv medio observer [m/s]	10.4	8.9	**2.8**
Δv medio comm [m/s]	11.7	9.3	**1.1**
Connettività media λ_2	2.06	2.28	1.53

Tabella 3: Confronto quantitativo sintetico fra le tre varianti, $N = 10\,000$ episodi valutati con politica deterministica.

7 Conclusioni

Questa tesi ha sviluppato e confrontato tre varianti di un ambiente Gymnasium per il controllo, tramite RL multi-agente on-policy, di una formazione di quattro satelliti, target passivo, chaser, observer e comm, nell'intorno di un'orbita Halo Sud-polare L_2 Terra-Luna. Le tre varianti condividono un impianto metodologico comune: la dinamica completa del CR3BP, un motore di trasferimento basato su shooting di Lambert nel frame LVLH, tre agenti PPO indipendenti addestrati con un curriculum a cinque fasi con gate di convergenza, e una funzione di reward costruita secondo il principio del potential-based shaping. Su questo impianto comune, la tesi ha isolato e confrontato due variabili metodologiche distinte: la risoluzione temporale della simulazione e la struttura geometrica dell'obiettivo di formazione di observer e comm.

I risultati sperimentali, tutti su un campione di $N = 10\,000$ episodi indipendenti valutati con politica deterministica, mostrano tassi di successo del rendez-vous compresi tra il 93.6% (passo adattivo) e il 99.2% (quasi-halo), con il passo fisso in posizione intermedia al 96.8%. Il confronto sistematico tra passo fisso e passo adattivo ha mostrato, a parità di curriculum e iperparametri, una riduzione sistematica del consumo di Δv per tutti e tre gli agenti attivi, a fronte di un tasso di successo lievemente inferiore attribuibile a una minoranza ben identificabile di episodi problematici più che a un degrado diffuso delle prestazioni. L'estensione quasi-halo ha mostrato che l'ancoraggio a un toro invariante consente un mantenimento di formazione a un costo energetico nettamente inferiore per observer e comm rispetto alle varianti free-space, un risultato ottenuto solo dopo l'abbandono di un

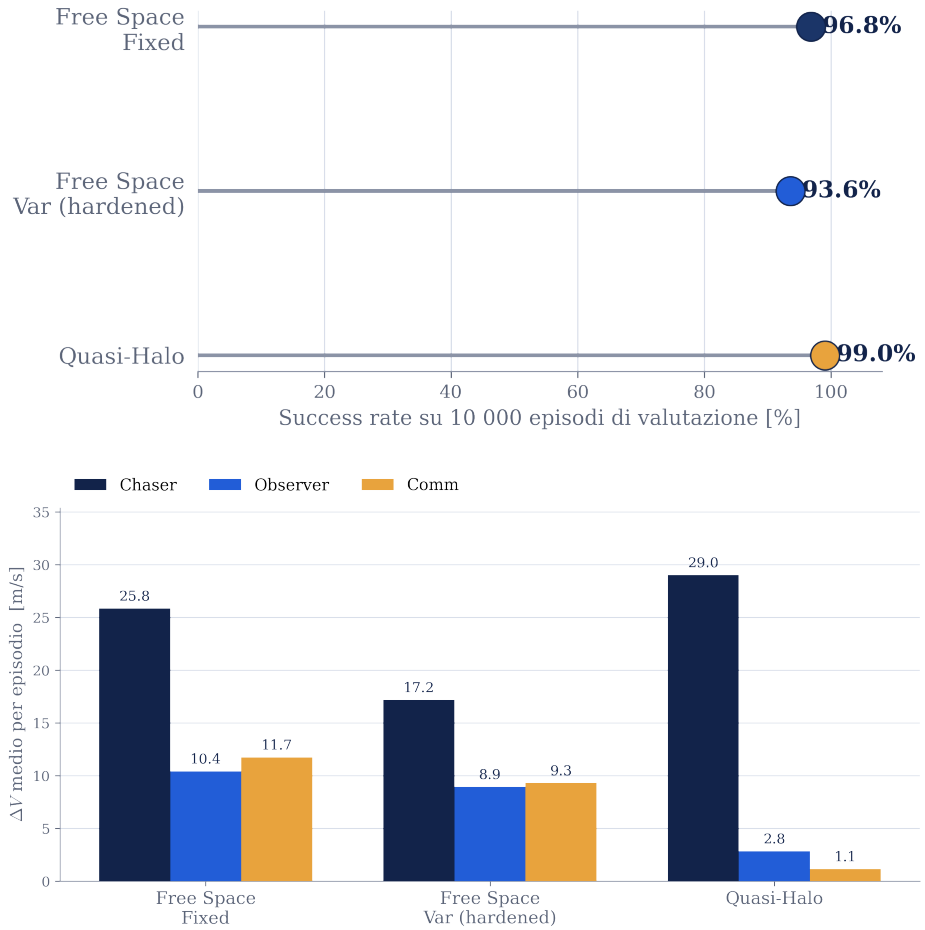


Figura 7: Confronto fra le tre varianti su $N = 10\,000$ episodi: tasso di successo del rendez-vous (sopra) e Δv medio per episodio dei tre agenti attivi (sotto).

primo modello puramente cinematico del toro e diverse ricalibrazioni della funzione di reward. Nel complesso, il confronto con l'approccio di ottimizzazione esplicita di riferimento [1] conferma che il RL multi-agente on-policy costituisce un'alternativa metodologicamente valida alla pianificazione esplicita per la gestione autonoma di formazioni satellitari in ambiente cislunare, capace di apprendere strategie di controllo competitive direttamente dall'interazione con la dinamica non lineare del sistema.

8 Sviluppi futuri

Coerentemente con i limiti discussi nella tesi, tre direzioni di sviluppo appaiono più immediate. In primo luogo, un **confronto diretto con architetture multi-agente più centralizzate** (MAPPO [4], MADDPG [5]), sullo stesso scenario di missione, permetterebbe di quantificare il costo in prestazioni della scelta, qui adottata, di evitare l'instabilità nota del training MARL centralizzato tramite un curriculum decentralizzato; su un piano complementare, l'estensione della formazione a più di tre satelliti attivi richiederebbe un'architettura di osservazione più scalabile dell'attuale concatenazione a dimensione fissa. In secondo luogo, l'**estensione del meccanismo di timestep adattivo alla variante quasi-halo**, che adotta per l'intera missione il passo fisso a 30 min, modulato non solo dalla distanza chaser-target ma anche dalla prossimità al perilunio della NRHO potrebbe produrre, anche per le manovre di hop e cambio-shell di observer e comm, un beneficio energetico analogo a quello osservato per il chaser free-space. Infine, un **passaggio verso modelli a maggiore fedeltà**: l'intero lavoro è stato condotto nell'ambito idealizzato del CR3BP, che trascura l'eccentricità reale dell'orbita lunare, le perturbazioni gravitazionali di Sole e altri corpi, la pressione di radiazione solare e le imperfezioni reali degli attuatori; un passaggio graduale verso un modello a *efemeridi reali* e l'introduzione di rumore ed errori di esecuzione delle manovre nell'ambiente di addestramento costituirebbero passi validi per ulteriori sviluppi del progetto.

Riferimenti bibliografici

[1] F. Pilone, *Autonomous Mission Management for Multi-Agent Lunar Mission*, Tesi di Laurea, Università di Pisa, 2024.

[2] W. S. Koon, M. W. Lo, J. E. Marsden, S. D. Ross, *Dynamical Systems, the Three-Body Problem and Space Mission Design*, Springer, 2011.

[3] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, *Proximal Policy Optimization Algorithms*, arXiv:1707.06347, 2017.

[4] C. Yu *et al.*, *The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games*, NeurIPS 35, 2022.

[5] R. Lowe *et al.*, *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments*, NeurIPS, 2017.

[6] Z. P. Olikara, D. J. Scheeres, *Numerical Method for Computing Quasi-Periodic Orbits and Their Stability in the Restricted Three-Body Problem*, Advances in the Astronautical Sciences 145, 2012.

[7] M. Tipaldi, R. Iervolino, P. R. Massenio, *Reinforcement Learning in Spacecraft Control Applications: Advances, Prospects, and Challenges*, Annual Reviews in Control 54, 2022.

[8] G. Bucchioni, M. Innocenti, *Rendezvous in Cis-Lunar Space near Rectilinear Halo Orbit: Dynamics and Control Issues*, Aerospace 8(3), 2021.

[9] N. Bosanac, S. Bonasera, C. J. Sullivan, J. McMahon, N. Ahmed, *Exploring Transfers Between Earth-Moon Halo Orbits via Multi-Objective Reinforcement Learning*, IEEE Aerospace Conference, 2021.

[10] L. Federici, B. Benedikter, A. Zavoli, *Deep Learning Techniques for Autonomous Spacecraft Guidance During Proximity Operations*, Journal of Spacecraft and Rockets 58(6), 2021.

[11] Q. Qu, K. Liu, W. Wang, J. Lü, *Spacecraft Proximity Maneuvering and Rendezvous with Collision Avoidance Based on Reinforcement Learning*, IEEE Transactions on Aerospace and Electronic Systems 58(6), 2022.

[12] À. Jorba, J. J. Masdemont, *Dynamics in the Center Manifold of the Collinear Points of the Restricted Three Body Problem*, Physica D 132(1–2), 1999.

[13] G. Gómez, J. J. Masdemont, C. Simó, *Quasihalo Orbits Associated with Libration Points*, Journal of the Astronautical Sciences 46(2), 1999.

[14] M. Towers *et al.*, *Gymnasium: A Standard Interface for Reinforcement Learning Environments*, Farama Foundation, 2023.

[15] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, N. Dormann, *Stable-Baselines3: Reliable Reinforcement Learning Implementations*, Journal of Machine Learning Research 22(268), 2021.

[16] K. C. Howell, H. J. Pernicka, *Station-Keeping Method for Libration Point Trajectories*, Journal of Guidance, Control, and Dynamics 16(1), 1993.